

**INFORMATION SYSTEM INOVATION AND NEW  
TECHNOLOGIES  
ARTIFICIAL INTELLIGENCE**

**PEMANFAATAN ARTIFICIAL INTELLIGENCE DALAM  
BIDANG PERTANIAN**



<b>Nama</b>	<b>NIM</b>
<i>Bagus Indrayana</i>	<i>1941018</i>
<i>Abdul Rahman</i>	<i>1941013</i>
<i>Hafidz Ramadhan Jauhari</i>	<i>1841090</i>

**PROGRAM STUDI SISTEM INFORMASI  
FAKULTAS ILMU KOMPUTER  
UNIVERSITAS MULIA  
SAMARINDA  
2022**

## DAFTAR ISI

<b>DAFTAR ISI.....</b>	<b>II</b>
<b>DAFTAR GAMBAR.....</b>	<b>III</b>
<b>DAFTAR TABEL .....</b>	<b>IV</b>
<b>BAB I PENDAHULUAN.....</b>	<b>5</b>
<b>1.1 Latar Belakang.....</b>	<b>5</b>
<b>1.2 Manfaat .....</b>	<b>5</b>
1.2.1 Memprediksi dan mengantisipasi masalah pertanian.....	5
1.2.2 Meningkatkan kualitas produk pertanian .....	6
<b>BAB II PEMBAHASAN.....</b>	<b>7</b>
<b>2.1 Resume Jurnal.....</b>	<b>7</b>
2.1.1 Penerapan Wahana Terbang Tanpa Awak untuk Memprediksi Waktu Panen pada Lahan Pertanian Berbasis Pengolahan Citra Digital.....	7
2.1.2 Identifikasi Tingkat Kematangan Buah Naga Merah ( <i>Hylocereus</i> <i>Costaricensis</i> ) Melalui Pendekatan <i>Artificial Neural Network</i> (ANN). ....	7
2.1.3 Klasifikasi Penyakit Tanaman pada Daun Kentang dengan <i>Metode</i> <i>Convolutional Neural Network</i> Arsitektur <i>MobileNet</i> . ....	8
<b>2.2 Hasil Pembahasan Jurnal.....</b>	<b>9</b>
2.2.1 Penerapan Wahana Terbang Tanpa Awak untuk Memprediksi Waktu Panen pada Lahan Pertanian Berbasis Pengolahan Citra Digital. ....	9
2.2.2 Identifikasi Tingkat Kematangan Buah Naga Merah ( <i>Hylocereus</i> <i>Costaricensis</i> ) Melalui Pendekatan <i>Artificial Neural Network</i> (ANN). ....	17
2.2.3 Klasifikasi Penyakit Tanaman pada Daun Kentang dengan <i>Metode</i> <i>Convolutional Neural Network</i> Arsitektur <i>MobileNet</i> . ....	20
<b>BAB III PENUTUP.....</b>	<b>28</b>
<b>3.1 Kesimpulan .....</b>	<b>28</b>
<b>3.2 Saran .....</b>	<b>28</b>
<b>DAFTAR PUSTAKA .....</b>	<b>29</b>

## DAFTAR GAMBAR

Gambar 2.2.1.1 Rangkaian Raspberry & Drone .....	10
Gambar 2.2.1.2 Konversi Koordinat ke Meter.....	10
Gambar 2.2.1.3 hasil konversi koordinat ke meter .....	11
Gambar 2.2.1.4 <i>Interface Algoritma SVM</i> (atas), <i>Confusion Matrix</i> (bawah) .....	12
Gambar 2.2.1.5 <i>Interface Algoritma MLP</i> (atas), <i>Confusion Matrix</i> (bawah).....	13
Gambar 2.2.1.6 Hasil Prediksi Waktu Panen.....	16
Gambar 2.2.1.7 Uji Coba Bot Telegram Gambar .....	17
Gambar 2.2.2.1 Rancangan Halaman Utama .....	18
Gambar 2.2.2.2 Proses Buka Citra .....	19
Gambar 2.2.2.3 Proses Data Testing dan Identifikasi Label.....	19
Gambar 2.2.3.1 Hasil Pengujian Terhadap <i>Optimizer</i> .....	21
Gambar 2.2.3.2 Hasil Pengujian Terhadap Learning Rate.....	21
Gambar 2.2.3.3 Grafik Pengujian Learning Rate 0,1 .....	22
Gambar 2.2.3.4 Grafik Pengujian <i>Learning Rate</i> 0,01 .....	23
Gambar 2.2.3.5 Grafik Pengujian Learning Rate 0,001 .....	23
Gambar 2.2.3.6 Grafik Pengujian <i>Learning Rate</i> 0,0001 .....	24
Gambar 2.2.3.7 Hasil Pengujian Terhadap Epoch .....	25
Gambar 2.2.3.8 Hasil pengujian terhadap Batch Size.....	25
Gambar 2.2.3.9 Hasil Confussion Matrix. ....	27

## **DAFTAR TABEL**

Tabel 2.2.1.1 hasil akurasi keseluruhan .....	14
Tabel 2.2.3.1 Pembagian Dataset .....	20
Tabel 2.2.3.2 Hasil Pengujian Terbaik .....	26
Tabel 2.2.3.3 Nilai Performansi Sistem .....	27

# **BAB I**

## **PENDAHULUAN**

### **1.1 Latar Belakang**

Kecerdasan buatan atau *artificial intelligence* (AI) merupakan teknologi yang memungkinkan komputer untuk melakukan tugas-tugas yang biasanya dilakukan oleh manusia, seperti belajar, memecahkan masalah, dan mengambil keputusan. Dalam bidang pertanian, AI dapat digunakan untuk membantu dalam berbagai aspek, mulai dari penyiraman, pemupukan, dan penyiangan hingga pemantauan kondisi tanaman dan peramalan hasil panen.

Penggunaan AI di bidang pertanian dapat membantu meningkatkan efisiensi dan produktivitas pertanian, serta mengurangi biaya produksi. Selain itu, AI juga dapat membantu meningkatkan kualitas produk pertanian dengan memantau kondisi tanaman secara terus-menerus dan memberikan saran tindakan yang tepat untuk memelihara kondisi tanaman yang optimal.

Dengan demikian, pemanfaatan AI di bidang pertanian merupakan salah satu solusi untuk meningkatkan produktivitas dan efisiensi pertanian, serta mengurangi dampak negatif dari praktik pertanian terhadap lingkungan. Namun, meskipun AI dapat memberikan banyak manfaat bagi pertanian, terdapat juga beberapa tantangan yang perlu diperhatikan dalam implementasinya, seperti biaya yang dibutuhkan untuk membeli dan mengoperasikan sistem AI, serta risiko kegagalan sistem yang dapat menyebabkan kerugian bagi petani.

### **1.2 Manfaat**

#### **1.2.1 Memprediksi dan mengantisipasi masalah pertanian**

Kecerdasan buatan dapat membantu petani mengidentifikasi masalah seperti kekeringan, penyakit tanaman, atau hama, serta memberikan saran tentang cara mengatasinya.

### **1.2.2 Meningkatkan kualitas produk pertanian**

Kecerdasan buatan dapat membantu petani mengoptimalkan proses pengolahan produk pertanian seperti penyortiran dan pemrosesan bahan makanan, sehingga meningkatkan kualitas dan nilai tambah produk pertanian.

## **BAB II**

### **PEMBAHASAN**

#### **2.1 Resume Jurnal**

##### **2.1.1 Penerapan Wahana Terbang Tanpa Awak untuk Memprediksi Waktu Panen pada Lahan Pertanian Berbasis Pengolahan Citra Digital.**

Pemanfaatan wahana terbang tanpa awak atau *drone* hingga saat ini telah banyak digunakan pada bidang pertanian antara lain untuk penyemprotan pestisida, pemetaan lahan, hingga memprediksi waktu panen. Penelitian ini menghadirkan hasil prediksi waktu panen untuk pertanian padi. Selama ini petani mengetahui padi yang siap panen hanya melalui fisik tanaman padi seperti tanaman padi mulai menguning, tangkai padi menunduk dan butir padi terasa keras apabila ditekan. Jadi harus diusahakan rekayasa yang dapat membantu memberikan data berupa estimasi waktu panen. Tahapan penelitian ini dimulai dari pengambilan citra pada lahan pertanian menggunakan *drone*. *Drone* juga dilengkapi dengan GPS yang nantinya akan digunakan untuk memperkirakan ukuran lahan pertanian. Kemudian citra tersebut akan dikirimkan menuju laptop. Pada laptop akan dilakukan proses ekstraksi fitur yaitu fitur warna, fitur bentuk dan fitur tekstur. Kemudian nilai-nilai ekstraksi fitur tersebut akan dijadikan data latih dan data uji. Dalam proses klasifikasi penelitian ini menggunakan algoritma *SVM(support vector machine)*, *K-Nearest Neighbor* dan *Multi Layer Perceptron*. Hasil yang didapatkan algoritma *Multi Layer Perceptron* memiliki performa paling baik dengan rerata tingkat akurasi sebesar 84%, rerata *precision* sebesar 0,85, rerata *recall* sebesar 0,83 dan rerata *F1 score* sebesar 0,84. Setelah itu hasil klasifikasi akan di simpan pada *Google Spreadsheet* sebagai *database* untuk Bot Telegra (Pratama dkk., 2022).

##### **2.1.2 Identifikasi Tingkat Kematangan Buah Naga Merah ( *Hylocereus Costaricensis*) Melalui Pendekatan Artificial Neural Network (ANN).**

Perkembangan teknologi yang masif terus terjadi dan merambah ke segala sektor kehidupan masyarakat dunia. Di Indonesia khususnya, perlu dilakukan berbagai penelitian untuk mengembangkan berbagai teknologi 4.0 di bidang

pertanian dan menerapkannya untuk meningkatkan kualitas dan kuantitas hasil produksi. Salah satu teknologi di bidang pertanian yang perlu dikembangkan adalah identifikasi kematangan buah, di mana hal ini perlu dilakukan mengingat keterbatasan indra manusia dalam menentukan tingkat kematangan berdasarkan nilai RGB dari buah. Dalam penelitian ini dilakukan pendekatan *Artificial Neural Network* (ANN) dengan algoritma *Backpropagation*. *Dataset* yang digunakan terdiri dari 90 foto buah naga untuk data *training* dan 15 foto buah naga untuk data *testing*. Adapun hasil yang didapatkan yaitu model ANN yang dibangun mampu melakukan identifikasi tingkat kematangan buah dengan akurasi 100% berdasarkan *dataset* yang digunakan (Armiady, 2022).

### **2.1.3 Klasifikasi Penyakit Tanaman pada Daun Kentang dengan Metode Convolutional Neural Network Arsitektur MobileNet.**

Pertanian merupakan hal yang sangat penting bagi manusia karena secara langsung berhubungan dengan produksi pangan. Salah satu produksi pangan yang dikonsumsi masyarakat adalah kentang. Kentang tidak hanya dikonsumsi sebagai makanan pokok tetapi dapat juga dijadikan bahan dasar untuk membuat cemilan. Dengan banyaknya yang produksi kentang saat ini maka semakin sulit untuk petani dalam memeriksa kualitas dan kuantitas kentang. Penyakit pada daun kentang merupakan salah satu faktor yang mempengaruhi kualitas kentang. Pertumbuhan pesat teknologi saat ini membuat manusia menciptakan *Artificial Intelligence* (AI). AI juga dapat disebut sebagai kecerdasan buatan pada teknologi mesin yang mengimplementasikan kecerdasan manusia. AI yang didasari oleh *Deep Learning* untuk proses klasifikasi pengolahan citra menggunakan metode *Convolutional Neural Network* memiliki kinerja yang lebih unggul. Dengan menggunakan salah satu arsitektur yaitu *MobileNet* yang memiliki kelebihan *low cost*, *stable* dan *high precision*. Penelitian ini akan melakukan klasifikasi penyakit pada daun kentang yaitu *early blight*, *late blight* dan *healthy*. Dengan menggunakan metode CNN arsitektur *MobileNet* terdapat empat skenario pengujian untuk mendapatkan hasil terbaik. Hasil terbaik dari setiap skenario menggunakan *optimizer* RMSprop, *learning rate* 0,0001, *epochs* 50 dan *batch size* 32 memperoleh akurasi 97,90% dan *loss* 0,0390 (Ompusunggu, 2022).



## 2.2 Hasil Pembahasan Jurnal

Untuk mengetahui sejauh mana pemanfaatan *Artificial Intelligence* atau kecerdasan buatan khususnya di bidang pertanian berikut ini merupakan beberapa contoh pemanfaatan teknologi *Artificial Intelligence* atau kecerdasan buatan dalam bidang pertanian dan di lingkungan masyarakat.


### 2.2.1 Penerapan Wahana Terbang Tanpa Awak untuk Memprediksi Waktu Panen pada Lahan Pertanian Berbasis Pengolahan Citra Digital.

*Drone* merupakan salah satu jenis wahana terbang tanpa awak. *drone* adalah salah satu teknologi yang sedang mengalami perkembangan yang pesat dan memiliki potensi yang sangat besar, baik untuk keperluan militer maupun kepentingan sipil.

Penelitian ini menggunakan *drone* syma X8Pro, penelitian ini melakukan pengambilan citra pada lahan pertanian padi untuk memperkirakan waktu panen. *Drone* ini juga terdapat data GPS saat *drone* terbang dari suatu titik ke titik yang ditentukan. Data tersebut akan dikirimkan menuju laptop yang berada di darat. Pada laptop, dilakukan ekstraksi fitur yaitu fitur bentuk, fitur warna dan fitur tekstur untuk mencari daerah fitur yang signifikan pada gambar berdasarkan karakteristiknya. Kemudian hasil ekstraksi fitur yang terkumpul dilatih dan diklasifikasikan menggunakan algoritma *SVM*(*support vector machine*), *KNN*(*K-Nearest Neighbor*) dan *MLP*(*Multi Layer Perceptron*) untuk memperkirakan waktu panen tanaman padi.



Gambar 4. Drone



Gambar 2.2.1.1 Rangkaian Raspberry &amp; Drone

Kemudian di pembahasan dilakukan pengujian, pengujian terdiri dari 2 macam yaitu pengujian perhitungan ukuran lahan menggunakan data GPS dari drone serta pengujian klasifikasi perkiraan waktu panen padi. Untuk pengujian perhitungan ukuran lahan mencatat data *latitude* dan *longitude* dari titik-titik ujung lahan sebanyak 5 data yang kemudian dilakukan rata-rata, nilai hasil rata-rata inilah yang nantinya dijadikan *input* pada *interface* seperti gambar dibawah.

Konversi ke meter	
Lat 1	-7.24809
Long 1	112.624911
Lat 2	-7.2477816
Long 2	112.62483
Hasil :	35 meter
<input type="button" value="ubah"/>	

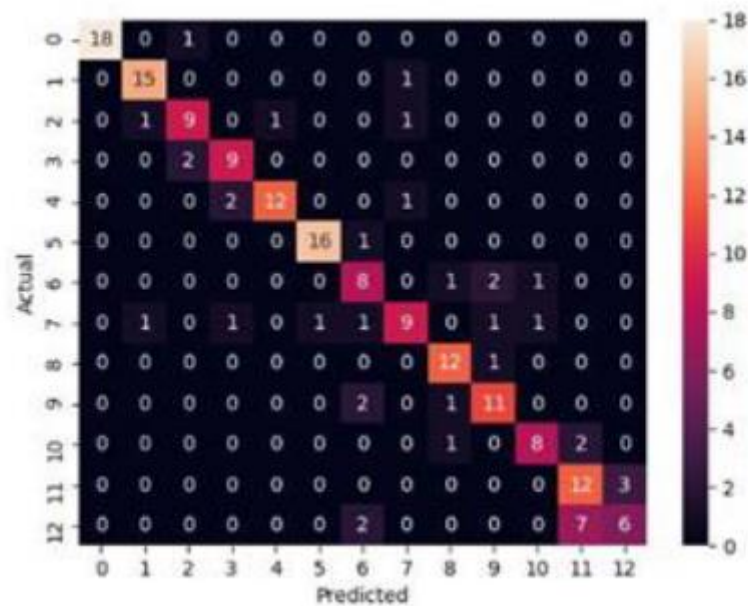
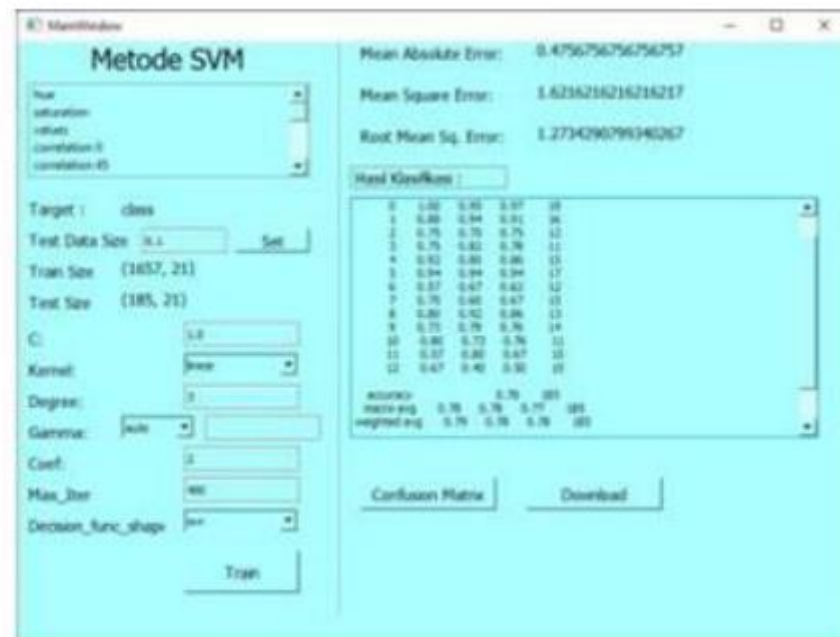
Gambar 2.2.1.2 Konversi Koordinat ke Meter

Hasil perbandingan dari konversi menggunakan *software* dengan data dari petani seperti gambar di bawah.

Lahan	software	petani	akurasi
1	P = 31 m L = 35 m Luas=1085 m <sup>2</sup>	Luas= 1050 m <sup>2</sup>	96,67%
2	P = 56 m L = 35 m Luas=1960 m <sup>2</sup>	Luas = 1960 m <sup>2</sup>	100%
3	P=19 m L= 56 m Luas= 1064 m <sup>2</sup>	Luas= 1100 m <sup>2</sup>	96,73%
4	P=10m L=51m Luas = 510 m <sup>2</sup>	Luas = 570 m <sup>2</sup>	89,47%
5	P=11m L=50m Luas = 550 m <sup>2</sup>	Luas = 600 m <sup>2</sup>	91,67%

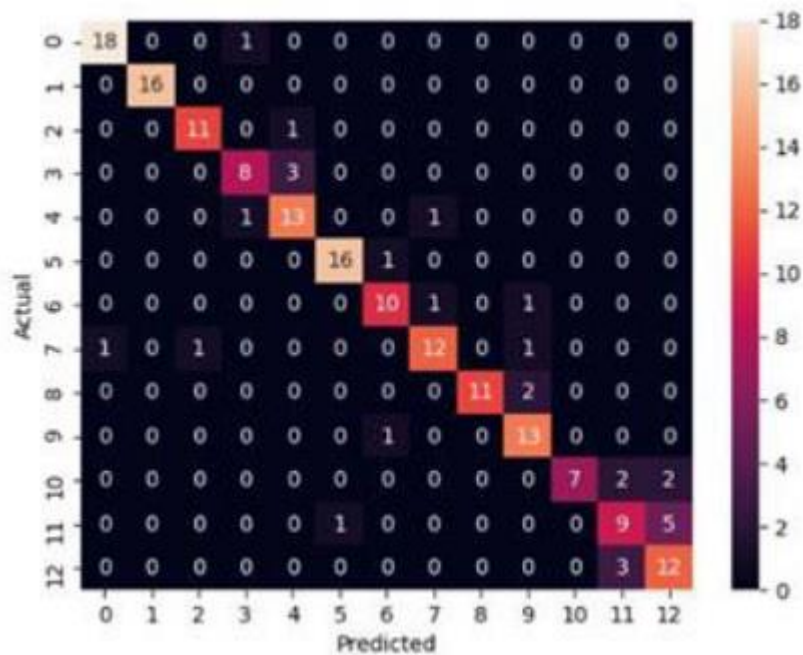
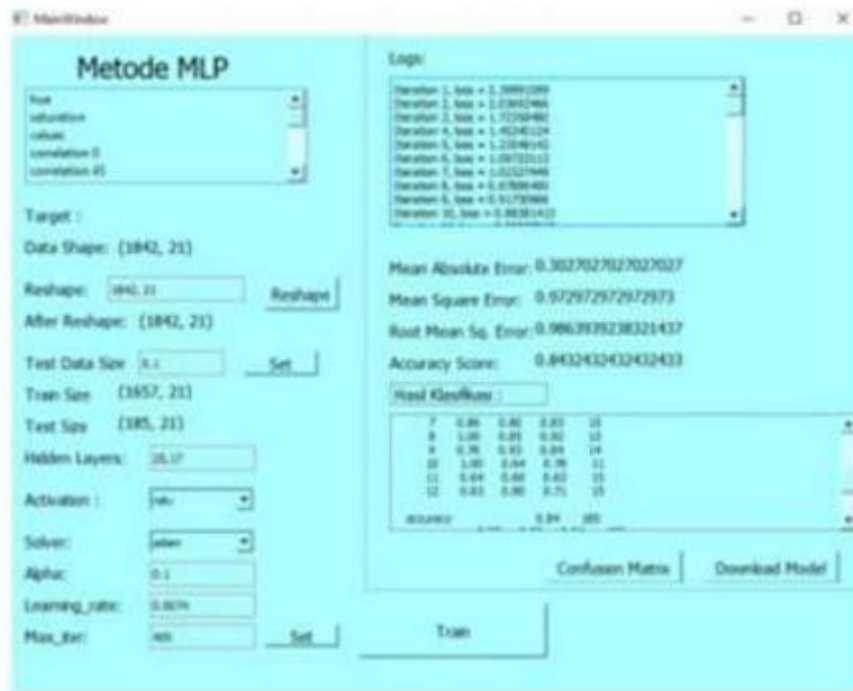
Gambar 2.2.1.3 hasil konversi koordinat ke meter

Pada uji coba perkiraan waktu panen menggunakan *split* data 0.1 jadi 90% berupa data *train* sedangkan 10% berupa data *test* dimana total datasheet sebanyak 1842 data dipecah menjadi 1657 sebagai data *train* dan 185 menjadi data test. Keluaran hasil prediksi dalam bentuk *confusion matrix*, pada pengujian algoritma SVM menggunakan parameter  $c=1$ , *kernel* menggunakan linier, *degree*=3, *gamma*=auto, *coefisien*= 2, iterasi *max*= 400 dan *decision* menggunakan ovr yang terlihat seperti gambar di bawah ini



Gambar 2.2.1.4 Interface Algoritma SVM (atas), *Confusion Matrix*(bawah)

Pada uji coba algoritma MLP menggunakan parameter hidden layer =25, 17, aktivasi menggunakan *relu*, *solver* = adam, *learning rate*= 0.0074 dan iterasi max= 400. Keluaran hasil prediksi dalam bentuk *confusion matrix* seperti gambar di bawah



Gambar 2.2.1.5 Interface Algoritma MLP(atas), Confusion Matrix(bawah)

Setelah mendapatkan *confusion matrix* maka dapat dilakukan perhitungan nilai akurasi, *precision*, *recall* dan *F1 score* secara teori untuk membuktikan bahwa

hasil perhitungan teori dan hasil penelitian tidak jauh berbeda dengan menggunakan persamaan (9), (10), (11) dan (12).

$$\text{Akurasi} = \text{TP total} / \text{total data test} \quad (9)$$

$$\text{Precision(P) (total)} = \sum(\text{TP} / (\text{TP} + \text{FP})) / \text{jumlah kelas} \quad (10)$$

$$\text{Recal(total)} = \sum(\text{TP} / (\text{TP} + \text{FN})) / \text{jumlah kelas} \quad (11)$$

$$\text{F1 score(total)} = 2 * (\text{Recall} * \text{Precision}) / (\text{Recall} + \text{Precision}) \quad (12)$$

Yang didapatkan hasil prediksi waktu panen seperti table berikut.

NO	Nilai	SVM		KNN		MLP	
		Percobaan	Teori	Percobaan	Teori	Percobaan	Teori
1	Akurasi	0.78	0.78	0,76	0,76	0,84	0,84
2	Precision	0.78	0.78	0,76	0,76	0,85	0,85
3	Recall	0.78	0.78	0,74	0,74	0.83	0.83
4	F1 score	0.77	0.78	0,74	0,75	0.84	0.84

Tabel 2.2.1.1 hasil akurasi keseluruhan

Pada tabel di atas dapat diketahui bahwa ada sedikit perbedaan nilai percobaan dan nilai teori pada nilai *F1 score* hasil dari menggunakan metode SVM dan KNN kemudian nilai akurasi tertinggi didapat ketika menggunakan metode MLP dengan akurasi 84%. Kemudian dari *confusion matrix* bisa didapatkan hasil akurasi dari setiap data *test* yang ada.

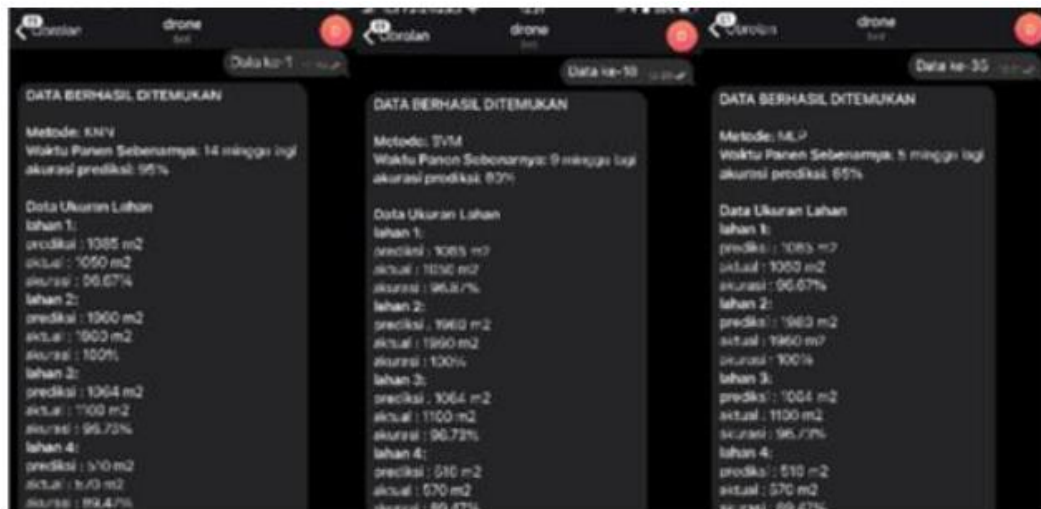
Data ke-n	Metode	aktual	akurasi
Data ke-1	KNN	14 minggu lagi	95%
Data ke-2	KNN	12 minggu lagi	100%
Data ke-3	KNN	11 minggu lagi	67%
Data ke-4	KNN	10 minggu lagi	64%
Data ke-5	KNN	9 minggu lagi	93%
Data ke-6	KNN	8 minggu lagi	88%
Data ke-7	KNN	7 minggu lagi	83%
Data ke-8	KNN	6 minggu lagi	73%
Data ke-9	KNN	5 minggu lagi	77%
Data ke-10	KNN	4 minggu lagi	86%
Data ke-11	KNN	2 minggu lagi	45%
Data ke-12	KNN	1 minggu lagi	60%
Data ke-13	KNN	panen	33%
Data ke-14	SVM	14 minggu lagi	95%
Data ke-15	SVM	12 minggu lagi	94%
Data ke-16	SVM	11 minggu lagi	75%
Data ke-17	SVM	10 minggu lagi	82%
Data ke-18	SVM	9 minggu lagi	80%
Data ke-19	SVM	8 minggu lagi	94%
Data ke-20	SVM	7 minggu lagi	67%
Data ke-21	SVM	6 minggu lagi	60%
Data ke-22	SVM	5 minggu lagi	92%
Data ke-23	SVM	4 minggu lagi	79%
Data ke-24	SVM	2 minggu lagi	73%
Data ke-25	SVM	1 minggu lagi	80%

Data ke-26	SVM	panen	40%
Data ke-27	MLP	14 minggu lagi	95%
Data ke-28	MLP	12 minggu lagi	100%
Data ke-29	MLP	11 minggu lagi	92%
Data ke-30	MLP	10 minggu lagi	73%
Data ke-31	MLP	9 minggu lagi	87%
Data ke-32	MLP	8 minggu lagi	94%
Data ke-33	MLP	7 minggu lagi	83%
Data ke-34	MLP	6 minggu lagi	80%
Data ke-35	MLP	5 minggu lagi	85%
Data ke-36	MLP	4 minggu lagi	93%
Data ke-37	MLP	2 minggu lagi	64%
Data ke-38	MLP	1 minggu lagi	60%
Data ke-39	MLP	panen	80%

Gambar 2.2.1.6 Hasil Prediksi Waktu Panen

Kemudian setelah mendapatkan hasil percobaan maka tahap terakhir pengujian adalah uji coba terhadap *Bot Telegram*, semua fungsi akan diuji dalam pengujian bot telegram. Fungsi yang digunakan untuk memanggil data dari *Google Spreadsheet*.

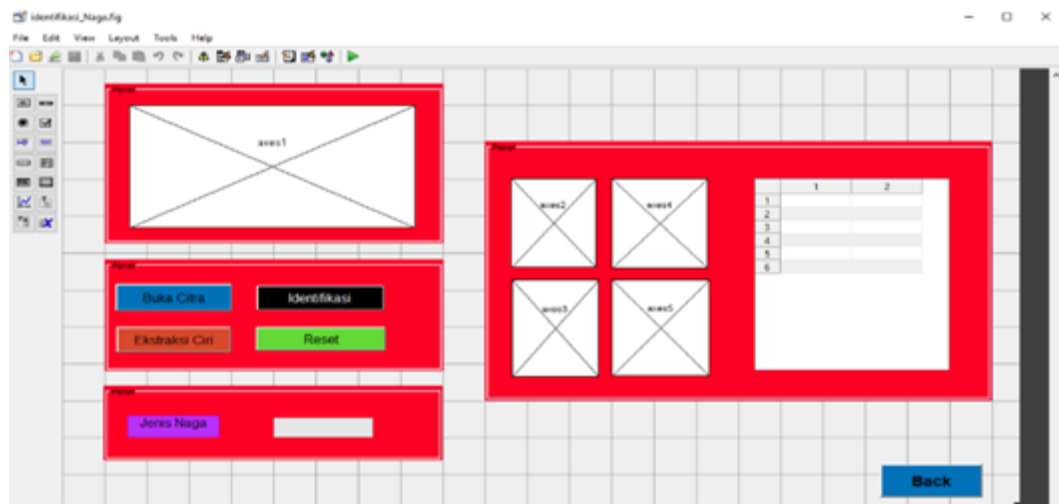




Gambar 2.2.1.7 Uji Coba Bot Telegram Gambar

## 2.2.2 Identifikasi Tingkat Kematangan Buah Naga Merah ( *Hylocereus Costaricensis*) Melalui Pendekatan *Artificial Neural Network* (ANN).

Penelitian ini menggunakan algoritma *backpropagation* yang di mana bertujuan untuk menentukan akurasi prediksi dari tingkat kematangan buah naga merah untuk itu terlebih dahulu memerlukan pengumpulan data sebagai data *training* yaitu 90 sampel foto buah naga merah yang terdiri dari 3 kelompok yaitu mentah, setengah matang, dan matang. Adapun data testing yang digunakan yaitu 15 sampel foto buah naga yang dikelompokkan data, di mana tiap kelompok terdiri dari 5 foto buah naga merah. Kemudian dibuatlah Aplikasi identifikasi tingkat kematangan buah naga merah dengan menggunakan aplikasi *MatLab* dengan rancangan sebagai berikut :



Gambar 2.2.2.1 Rancangan Halaman Utama

Pada halaman utama terdapat menu Buka Citra untuk memilih data testing yang akan dilakukan klasifikasi. Terdapat juga menu Ekstraksi Ciri, di mana jika menu ini dipilih maka akan muncul data *preprocessing* gambar buah naga melalui ekstraksi ciri dan nilai RGB, serta dilakukan *cropping* dan konversi citra ke bentuk *grayscale*. Pada halaman ini juga ada menu identifikasi untuk memproses data testing dengan hasil klasifikasi yang dapat dilihat pada menu hasil, sesuai dengan label klasifikasi yang telah ditentukan yaitu Mentah, Setengah Matang dan Matang. Setelah model dibangun melalui pelatihan mesin menggunakan data *training* dan algoritma *backpropagation*, maka langkah berikutnya yaitu dilakukan pengujian terhadap model yang dibangun dengan memasukkan data testing. Adapun proses

data testing dapat dilihat pada gambar berikut:



Gambar 2.2.2.2 Proses Buka Citra



Gambar 2.2.2.3 Proses Data Testing dan Identifikasi Label

Pada gambar di atas didapatkan hasil klasifikasi melalui proses Buka Citra untuk memilih data testing berupa foto buah naga, kemudian proses Ekstraksi Ciri untuk ekstraksi nilai RGB (*Red, Green, Blue*) dan HSV (*Hue, Saturation, Value*), kemudian proses Identifikasi untuk melakukan pengelompokan dengan menggunakan perhitungan-perhitungan dengan algoritma *backpropagation*. Adapun hasil dari pengujian model yang dibangun yaitu berhasil dengan persentase 100%. Hal ini diuji dengan menggunakan 5 data uji yang telah disediakan pada tahap sebelumnya.

### 2.2.3 Klasifikasi Penyakit Tanaman pada Daun Kentang dengan Metode Convolutional Neural Network Arsitektur MobileNet.

Pengujian sistem ini dilakukan dengan tujuan mendapatkan hasil performansi terbaik pada klasifikasi citra daun kentang dengan melihat nilai parameter akurasi, *loss*, *recall* presisi dan *F1-score*. Penelitian dilakukan dengan menggunakan *dataset* sebanyak 3000 citra daun yang terdiri dari tiga kelasi yaitu, *Early Blight*, *Late Blight* dan *Healthy*. Dataset tersebut akan akan dibagi menjadi data train, data validation dan data test yang dapat dilihat pada Tabel

Jumlah Dataset	Data Train	Data Validation	Data Test
3000 data	65% (1950 data)	25% (750 data)	10% (300 data)


Tabel 2.2.3.1 Pembagian Dataset

#### Skenario Pengujian Sistem

Sistem akan diuji dengan menggunakan empat skenario yaitu perbandingan terhadap *optimizer*, perbandingan terhadap *learning rate*, perbandingan terhadap *epoch* dan perbandingan terhadap *batch size*.

##### Skenario 1 : Pengujian Terhadap *Optimizer*

Pemilihan *optimizer* sangat penting untuk proses training, karena dapat pelatihan model secara signifikan. Skenario pertama adalah melakukan pengujian terhadap *optimizer*. Diketahui ketentuan *hyperparameter* adalah *learning rate* 0,0001, jumlah epochs 100 dan batch size 32.




Gambar 2.2.3.1 Hasil Pengujian Terhadap *Optimizer*

Berdasarkan Gambar mendapatkan hasil yang efisien pada *optimizer* RMSprop dengan nilai akurasi 97,90% dan nilai *loss* 0,0390. *Optimizer* RMSprop (*Root Mean Square Propagation*) adalah metode optimasi untuk mempertahankan nilai learning rate dengan rata-rata dari gradien.

#### Skenario 2 : Pengujian Terhadap *Learning Rate*


Skenario kedua adalah melakukan pengujian terhadap nilai *learning rate* dengan menggunakan hasil analisis terbaik pada skenario pertama. Nilai *learning rate* yang digunakan dalam skenario ini yaitu 0,1; 0,01; 0,001; 0,0001 dengan ketentuan *optimizer* RMSprop, jumlah *epochs* 100 dan *batch size* 32. Hasil pengujian terhadap *learning rate* diilustrasikan pada Gambar dibawah



Gambar 2.2.3.2 Hasil Pengujian Terhadap Learning Rate

Learning Rate 0,1

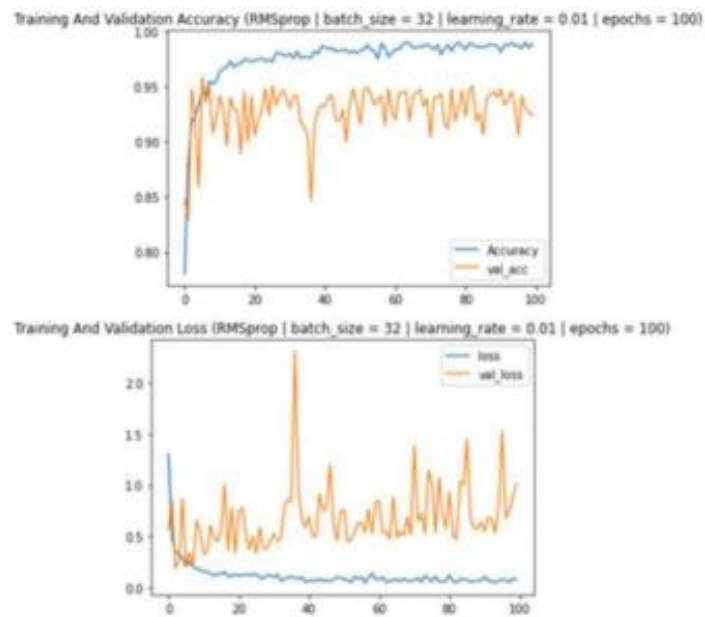
Berdasarkan pengujian terhadap *learning rate* 0,1 didapatkan hasil akurasi yang cukup tinggi yaitu 98,56% tetapi nilai *loss* 0,7702. Berdasarkan hasil tersebut model dapat dinilai cukup baik karena akurasi semakin tinggi dan *loss* semakin rendah tetapi pada garis akurasi dan garis *validation* akurasi se-dikit berjauhan. Grafik yang dihasilkan menunjukkan bahwa hasil *validation* akurasi dan *validation loss* memberikan nilai yang berubah-ubah sangat drastis sehingga model dapat dikatakan *underfitting*. Hasil pengujian *learning rate* 0,1 diilustrasikan pada Gambar berikut



Gambar 2.2.3.3 Grafik Pengujian Learning Rate 0,1

#### *Learning Rate* 0,01

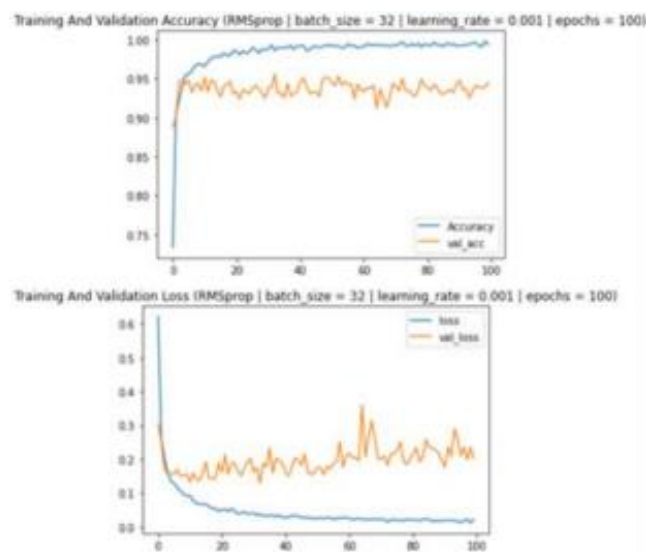
Berdasarkan pengujian terhadap *learning rate* 0,01 didapatkan hasil akurasi yang cukup tinggi yaitu 98,87% tetapi nilai *loss* 0,0796. Berdasarkan hasil tersebut model dapat dinilai cukup baik karena akurasi semakin tinggi dan *loss* semakin rendah tetapi pada garis akurasi dan garis *validation* akurasi sedikit berjauhan. Grafik yang dihasilkan menunjukkan bahwa hasil *validation* akurasi dan *validation loss* memberikan nilai yang berubah-ubah sehingga model dapat dikatakan *underfitting*. Hasil pengujian *learning rate* 0,01 diilustrasikan pada Gambar dibawah



Gambar 2.2.3.4 Grafik Pengujian *Learning Rate* 0,01

#### *Learning rate* 0,001

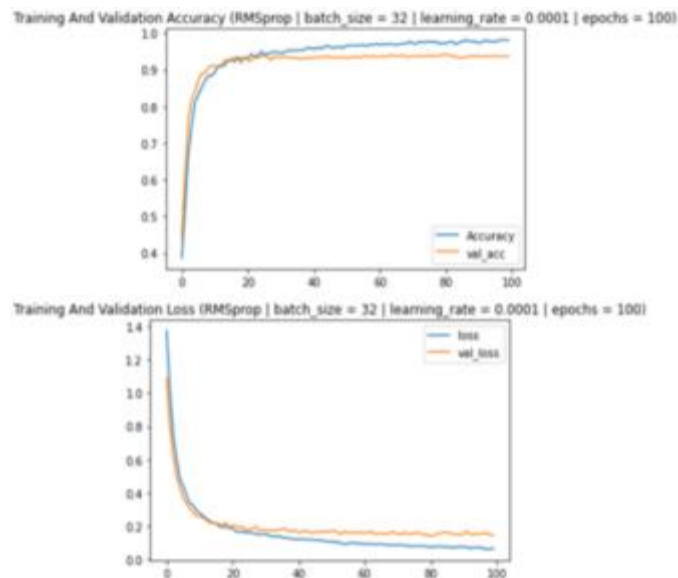
Berdasarkan pengujian terhadap *learning rate* 0,001 didapatkan hasil akurasi yang cukup tinggi yaitu 99,38% tetapi nilai *loss* 0,0213. Berdasarkan hasil tersebut model dapat dinilai cukup baik karena akurasi semakin tinggi dan *loss* semakin rendah tetapi pada garis akurasi dan garis validation akurasi sedikit berjauhan sehingga model dapat dikatakan *underfitting*. Hasil pengujian *learning rate* 0,001 diilustrasikan pada Gambar berikut



Gambar 2.2.3.5 Grafik Pengujian *Learning Rate* 0,001

### *Learning Rate 0,0001*

Nilai *learning rate* 0,0001 merupakan nilai yang paling efisien pada penelitian ini Berdasarkan pengujian terhadap *learning rate* 0,0001 didapatkan hasil akurasi yang cukup tinggi yaitu 97,90% tetapi nilai *loss* 0,039. Berdasarkan hasil tersebut model dapat dinilai cukup baik karena menghasilkan model yang *fitting*. Hasil pengujian *learning rate* 0,0001 diilustrasikan pada Gambar berikut




Gambar 2.2.3.6 Grafik Pengujian *Learning Rate* 0,0001

### Skenario 3 : Pengujian Terhadap *Epoch*

*Epoch* merupakan sebuah proses *training* yang dilakukan secara berulang-ulang untuk mencapai nilai akurasi yang optimum. Skenario ketiga adalah melakukan pengujian terhadap jumlah *epoch* dengan menggunakan hasil parameter terbaik pada skenario sebelumnya. Jumlah *epoch* yang akan diuji adalah 25, 50, 75 dan 100 dengan ketentuan *optimizer RMSprop*, nilai *learning rate* 0,0001 dan *batch size* 32. Hasil pengujian terhadap jumlah *epochs* diilustrasikan pada Gambar






Gambar 2.2.3.7 Hasil Pengujian Terhadap Epoch

Berdasarkan Gambar 4.7 mendapatkan hasil yang paling efisien pada pengujian ini jumlah *epoch* 100. Pada pengujian ini jumlah *epoch* 100 dengan memiliki nilai akurasi 97,90% dan nilai *loss* 0,0390. Dari nilai tersebut dilihat bahwa jumlah *epoch* 100 lebih baik dibandingkan dengan jumlah *epochs* 25, 50 dan 100, karena semakin banyak nilai *epoch* semakin banyak proses belajar pada model.

#### Skenario 4 : Pengujian Terhadap *Batch Size*

*Batch Size* adalah pembagian dataset per-batch pada *epochs* untuk mempercepat proses training. Skenario terakhir adalah melakukan pengujian terhadap *batch size* dengan menggunakan hasil parameter terbaik pada skenario sebelumnya. *Batch size* yang akan diuji adalah 16, 32, 64 dengan ketentuan *optimizer RMSprop*, nilai *learning rate* 0,0001 dan jumlah *epochs* 100. Hasil pengujian terhadap *batch size* diilustrasikan pada Gambar berikut



Gambar 2.2.3.8 Hasil pengujian terhadap Batch Size

Berdasarkan Gambar didapatkan hasil yang paling efisien pada pengujian *batch size* adalah 32. *Batch Size* 32 menghasilkan nilai akurasi 97,90% dan nilai *loss* 0,0390. Proses pembagian *dataset* dengan sebanyak 32 per-*batch* memberikan hasil efisien bagi model untuk proses belajarnya.

### Analisa Hasil Pengujian


Setelah melakukan pengujian terhadap empat skenario yaitu *optimizer*, *learning rate*, *epochs* dan *batch size* hasil yang paling berpengaruh terjadi pada *learning rate*. Pada penelitian ini didapatkan bahwa semakin besar nilai *learning rate*, maka semakin bagus hasil pengujiannya yang dapat ditunjukkan pada grafik yang tidak mengalami *overfitting* atau *underfitting*. Analisa hasil pengujian terbaik tiap skenario pada Tabel 1

Terdapat parameter lain untuk menentukan kinerja model terbaik adalah nilai performansi sistem berupa *Recall*, *Precision* dan *F1-Score* dengan menggunakan *Confussion Matrix*. Nilai performansi sistem diilustrasikan pada Tabel di bawah

Parameter	Nilai
Optimizer	RMSprop
Learning rate	0,0001
Epochs	100
Batch size	32
Akurasi Training	97,90%
Loss Training	0,0390
Akurasi Validation	99,38%
Loss Validation	0,2034

Tabel 2.2.3.2 Hasil Pengujian Terbaik

*Confussion Matrix* diilustrasikan pada Gambar dibawah



Gambar 2.2.3.9 Hasil Confussion Matrix.

Akurasi	Loss	Presisi	Recall	F1-Score
97,90%	0,0390	97%	97%	97%

Tabel 2.2.3.3 Nilai Performansi Sistem

Pada penelitian ini dengan menggunakan hasil pengujian terbaik akan dilakukan pelatihan ulang. Tujuan dilakukan pelatihan ulang adalah untuk melihat apakah model yang dibuat bekerja dengan baik sesuai dengan akurasi yang telah didapat. Pada penelitian ini didapatkan akurasi testing adalah 97,33% dan nilai *loss testing* adalah 0,1142, ini menunjukkan bahwa model dapat bekerja dengan baik selama pelatihan.

## **BAB III**

### **PENUTUP**

#### **3.1 Kesimpulan**

Dari bahasan beberapa jurnal di makalah ini dapat di simpulkan bahwa implementasi kecerdasan buatan atau *Artificial Intelligence* memiliki dampak yang cukup positif khususnya di bidang pertanian, di mana pemanfaatan ini dapat membantu petani dalam mengawasi kualitas hasil panen dengan memantau kondisi tanaman serta membantu memprediksi waktu panen sehingga dapat meningkatkan produksi hasil panen.

Walaupun begitu implementasi ini tidak lepas dari Kendala alat, biaya serta akurasi dari keputusan yang di buat oleh teknologi kecerdasan buatan ini, dimana perlu kajian dan pengembangan lebih lanjut lagi untuk bisa merancang sebuah alat yang mudah di beli oleh petani serta memiliki akurasi hasil yang dapat di terima.

#### **3.2 Saran**

Perlunya kajian dan pengembangan lebih lanjut lagi untuk bisa merancang sebuah alat yang mudah di beli oleh petani serta memiliki akurasi hasil yang dapat di terima, beberapa penelitian di atas menggunakan alat yang terbilang cukup mahal untuk di beli oleh petani jika-pun bisa di implementasi maka perlu suatu perusahaan yang dapat menyediakan dan menyewakan fasilitas ini ke petani.

Selain biaya alat yang relatif mahal penggunaan implementasi ini perlu di permudah agar bisa di gunakan oleh petani, beberapa penelitian di atas masih memiliki desain *user interface* yang masih tidak nyaman dan mudah di gunakan oleh petani.

## DAFTAR PUSTAKA

- Armiady, D. (2022). IDENTIFIKASI TINGKAT KEMATANGAN BUAH NAGA MERAH ( HYLOCEREUS COSTARICENSIS ) MELALUI PENDEKATAN ARTIFICIAL NEURAL NETWORK ( ANN ). *Jurnal Teknik Informasi Aceh*, 7(3), 265–273.
- Ompusunggu, P. T. (2022). KLASIFIKASI PENYAKIT TANAMAN PADA DAUN KENTANG DENGAN METODE CONVOLUTIONAL NEURAL NETWORK ARSITEKTUR MOBILENET. *Jurnal Nasional Indonesia*, 2(8.5.2017), 2003–2005.
- Pratama, R. A., Iman Nur, B., dan Arifin, F. (2022). Penerapan Wahana Terbang Tanpa Awak untuk Memprediksi Waktu Panen pada Lahan Pertanian Berbasis Pengolahan Citra Digital. *Jurnal Teknik Elektro*, 5(1), 56–62. <https://doi.org/10.30651/cl.v5i1.9100>